

Job Market - Etape 1 - Collecte des données

L'étape 1 du projet Job Market consiste à récupérer des données relatives à des offres d'emploi par l'intermédiaire de plusieurs API.

Après extraction d'un premier jeu de données brutes, la difficulté de l'exercice provient du fait que les attributs ne sont pas identiques selon les sources. Il convient donc de **normaliser** les données afin de créer **un seul schéma de données**.

Les sources proposées sont l'API France Travail et le site Indeed. Toutefois, le site Indeed ne propose pas d'API spécifique à la recherche d'offres d'emploi, et nécessiterait donc d'employer une méthode de scraping. Afin de disposer de données déjà ordonnées et de rester efficace dans la récolte de données, nous opterons pour les sources suivantes :

- API France Travail
- API Adzuna

L'objectif est de :

- documenter les champs disponibles dans chaque source ;
- identifier leur type de données ;
- comprendre leur signification ;
- préparer l'harmonisation des données entre les différentes API ;
- définir les champs qui seront conservés dans le modèle final.

2 fichiers JSON sont joints à ce document pour présenter un échantillon des données extraites des API France Travail et Adzuna.

1. API France Travail

1.1 Structure générale de la réponse

Après authentification OAuth2, nous obtenons un token autorisant l'envoi de requête à l'API pour une durée limitée. L'API est de type API REST et sera requêtée avec la bibliothèque **requests** de Python.

La réponse de l'API France Travail contient notamment une clé **resultats**, qui contient une liste d'offres d'emploi.

Chaque élément de **resultats** correspond donc à une offre d'emploi.

1.2 Champs d'une offre

Nous listons ici les champs de premier niveau de chaque offre renvoyée par l'API France Travail.

Champ	Type Python / JSON	Description
id	str	Identifiant unique de l'offre France Travail
intitule	str	Intitulé de l'offre tel qu'il est publié
description	str	Description détaillée du poste
dateCreation	str	Date et heure de création de l'offre, au format ISO 8601
dateActualisation	str	Date et heure de dernière actualisation
lieuTravail	dict	Informations géographiques sur le lieu de travail
romeCode	str	Code ROME du métier associé à l'offre, par exemple D1102
romeLibelle	str	Libellé du métier ROME, par exemple Boulangier / Boulangère
appellationlibelle	str	Appellation métier plus précise associée à l'offre
entreprise	dict	Informations sur l'entreprise
typeContrat	str	Code du type de contrat, par exemple CDI
typeContratLibelle	str	Libellé lisible du contrat
natureContrat	str	Nature du contrat, par exemple Contrat travail ou Contrat apprentissage
experienceExige	str	Code indiquant le niveau/caractère exigé de l'expérience
experienceLibelle	str	Libellé de l'expérience demandée

Champ	Type Python / JSON	Description
experienceCommentaire	str	Précisions éventuelles sur l'expérience
formations	list[dict]	Formations ou diplômes demandés
langues	list[dict]	Langues demandées
permis	list[dict]	Permis éventuellement demandés
outilsBureautiques	list[str]	Outils bureautiques demandés
competences	list[dict]	Compétences techniques ou savoirs associés à l'offre
salaire	dict	Informations relatives à la rémunération
dureeTravailLibelle	str	Durée et éventuellement conditions horaires de travail
dureeTravailLibelleConversion	str	Forme normalisée du temps de travail, par exemple Temps plein
complementExercice	str	Complément relatif aux conditions d'exercice
conditionExercice	str	Conditions particulières d'exercice
alternance	bool	Indique si l'offre relève de l'alternance
contact	dict	Informations de contact
agence	dict	Informations sur l'agence France Travail
nombrePostes	int	Nombre de postes proposés
accessibleTH	bool	Indique si l'offre est accessible aux travailleurs handicapés
deplacementCode	str	Code relatif aux déplacements professionnels
deplacementLibelle	str	Description des déplacements professionnels
qualificationCode	str	Code du niveau de qualification
qualificationLibelle	str	Libellé du niveau de qualification
codeNAF	str	Code NAF de l'activité de l'établissement
secteurActivite	str	Code du secteur d'activité
secteurActiviteLibelle	str	Libellé du secteur d'activité
trancheEffectifEtab	str	Tranche d'effectif de l'établissement, par exemple 1 ou 2 salariés
qualitesProfessionnelles	list[dict]	Qualités / savoir-être professionnels recherchés
origineOffre	dict	Informations sur l'origine de l'offre
offresManqueCandidats	bool	Indique si l'offre est identifiée comme rencontrant des difficultés de recrutement
contexteTravail	dict	Informations structurées sur le contexte et les conditions de travail**
entrepriseAdaptee	bool	Indique si l'employeur est une entreprise adaptée
employeurHandiEngage	bool	Indique si l'employeur est identifié comme employeur handi-engagé

2. Sous-structures France Travail

Certains champs sont eux-mêmes des objets ou des listes d'objets. Nous traitons ici les champs considérés comme pertinents pour la suite du projet.

2.1 lieuTravail

Champ source	Type	Description
lieuTravail.libelle	str	Localisation affichée dans l'offre
lieuTravail.codePostal	str	Code postal
lieuTravail.commune	str	Code ou identifiant de commune

2.2 entreprise

Champ source	Type	Description
<code>entreprise.nom</code>	<code>str</code>	Nom de l'entreprise
<code>entreprise.description</code>	<code>str</code>	Description éventuelle de l'entreprise
<code>entreprise.logo</code>	<code>str</code>	URL éventuelle du logo
<code>entreprise.url</code>	<code>str</code>	URL éventuelle de l'entreprise
<code>entreprise.entrepriseAdaptee</code>	<code>bool</code>	Indique si l'entreprise est adaptée

2.3 salaire

Champ source	Type	Description
<code>salaire.libelle</code>	<code>str</code>	Texte décrivant le salaire

2.4 competences

Le champ `competences` contient une liste d'objets.

Exemple générique :

```
[
  {
    "code": "...",
    "libelle": "...",
    "exigence": "..."
  }
]
```

Champ source	Type	Description
<code>competences[].code</code>	<code>str</code>	Code de la compétence
<code>competences[].libelle</code>	<code>str</code>	Description de la compétence
<code>competences[].exigence</code>	<code>str</code>	Niveau d'exigence associé

La notation `[]` signifie que `competences` est une liste et que les champs décrits appartiennent à chacun de ses éléments.

2.5 formations

Champ source	Type	Description
<code>formations[].codeFormation</code>	<code>str</code>	Code de formation
<code>formations[].domaineLibelle</code>	<code>str</code>	Domaine de formation
<code>formations[].niveauLibelle</code>	<code>str</code>	Niveau de formation
<code>formations[].commentaire</code>	<code>str</code>	Commentaire éventuel
<code>formations[].exigence</code>	<code>str</code>	Niveau d'exigence

3. API Adzuna

3.1 Structure générale

La réponse de l'API Adzuna contient notamment une clé `results`, qui contient une liste d'offres d'emploi.

Chaque élément de **results** correspond donc à une offre d'emploi.

Tous les champs ne sont pas obligatoirement complétés, par exemple certaines offres possèdent **salary_min** et **salary_max**, alors que d'autres ne les possèdent pas.

3.2 Champs d'une offre

Champ	Type Python / JSON	Description
id	str	Identifiant unique de l'offre chez Adzuna
title	str	Intitulé de l'offre d'emploi
description	str	Description textuelle de l'offre
created	str	Date et heure de publication/création de l'offre au format ISO 8601
redirect_url	str	URL Adzuna permettant d'accéder à l'offre originale
company	dict / objet	Informations sur l'entreprise ou l'organisme recruteur
category	dict / objet	Catégorie métier attribuée par Adzuna
location	dict / objet	Informations géographiques associées à l'offre
latitude	float	Latitude approximative de l'offre
longitude	float	Longitude approximative de l'offre
contract_type	str	Type de contrat, par ex. permanent ou contract
contract_time	str	Temps de travail, par ex. full_time ou part_time
salary_min	int ou float	Borne basse du salaire associé à l'offre
salary_max	int ou float	Borne haute du salaire associé à l'offre
salary_is_predicted	str	Indique si le salaire a été estimé par Adzuna ; dans l'extraction, la valeur est par exemple "0"
adref	str	Référence technique/interne utilisée par Adzuna pour identifier ou suivre l'annonce
__CLASS__	str	Métadonnée technique indiquant le type d'objet Adzuna retourné

4. Sous-structures Adzuna

Certains champs sont eux-mêmes des objets ou des listes d'objets. Nous traitons ici les champs considérés comme pertinents pour la suite du projet.

4.1 company

company

|– display_name str

|– **CLASS** str

4.2 category

category

|– tag str

|– label str

|– **CLASS** str

2.1 location

location

|– display_name str

|- area list[str]

|- **CLASS** str

5. Champs normalisés entre les sources

Cette section définit le schéma commun à construire à partir des données France Travail et Adzuna.

L'API France Travail fournit des données plus riches que l'API Adzuna. **Certains champs proposés par France Travail seront donc maintenus**, quitte à obtenir des valeurs “null” sur ces champs pour les modalités transmises par Adzuna.

Liste des champs France Travail maintenus après normalisation, malgré l'absence d'équivalence des champs Adzuna :

- **romeCode** : nomenclature de France Travail destinée à classer les métiers et les emplois. La première lettre du code ROME fournit le code du grand domaine de l'offre d'emploi, par exemple :
 - A : Agriculture / Pêche / Espaces verts et naturels / Soins aux animaux
 - B : Arts / Artisanat d'art
 - C : Banque / Assurance
 - C15 : Immobilier
 - ...
- **codeNAF** : (Nomenclature d'activités française) ce code est attribué par l'INSEE à une entreprise ou à un établissement selon son *activité principale*.
- **competences** et **formations** sont également maintenus, dans les champs qui nous intéressent, afin d'étoffer les informations dans le futur dashboard du projet.

Certains champs pourront éventuellement être complétés par des données issues de webscraping, notamment les données issues des entreprises les plus prolifiques.

5.1 Tableau final de mapping

Les données normalisées devront présenter un champ **source** qui indiquera soit France Travail soit Adzuna.

Le tableau suivant reprend le schéma normalisé proposé et précise, pour chaque champ, son type ainsi que sa correspondance dans les deux sources.

Champ normalisé	Type final	France Travail (champ / type)	Adzuna (champ / type)
id	str	id (str)	id (str)
title	str	intitule (str)	title (str)
company	str	entreprise.nom (str)	company.display_name (str)
description	str	description (str)	description (str)
creationDate	str	dateCreation (str)	created (str)
contractType	str	typeContrat (str)	contract_type (str)
contractTime	str	dureeTravailLibelleConverti (str)	contract_time (str)
locationPostalCode	str	lieuTravail.codePostal (str)	—
locationRegion	str	lieuTravail.libelle (str)	location.area[2] (list[str])
locationCity	str	lieuTravail.commune (str)	location.area[3] (list[str])
locationLatitude	float	lieuTravail.latitude (float)	latitude (float)
locationLongitude	float	lieuTravail.longitude (float)	longitude (float)
salary	float	salaire.libelle (str)	salary_min, salary_max (int / float)
url	str	origineOffre.urlOrigine (str)	redirect_url (str)
codeNAF	str	codeNAF (str)	—
categoryLabel	str	secteurActiviteLibelle (str)	category.label (str)
romeCode	str	romeCode (str)	—
romeLibelle	str	romeLibelle (str)	—
skills	list[str]	competences[].libelle (str)	—

Champ normalisé	Type final	France Travail (champ / type)	Adzuna (champ / type)
education	str	formations[].niveauLibelle (str)	—
educationField	str	formations[].domaineLibelle (str)	—

Les champs ayant besoin d’être processés avant intégration dans une BDD normalisée sont :

API France Travail

- `lieuTravail.libelle` → `locationRegion` : Le département doit être extrait d’une chaîne de caractère de la forme “34 - Montpellier”. Cette construction du libellé est **uniforme** sur l’ensemble des offres d’emplois.
- `salaire.libelle` → `salary` : le libellé fourni par France Travail est une chaîne de caractères saisie par l’API, mais dont le salaire doit être extrait.
 - Idée : extraire le(s) salaire(s) de la chaîne de caractères grâce à leur format uniforme = 4 chiffres, 1 point, 1 chiffre.
 - Faire la moyenne des résultats obtenus, car il est parfois indiqué une fourchette de salaires.

API Adzuna

- `location.area` → `locationRegion` : Le département se trouve de manière **uniforme** en 3ème position dans la liste du champ. On prendre donc `locationRegion = location.area[2]`
- `location.area` → `locationCity` : Lorsqu’elle est indiquée, la ville se trouve de manière **uniforme** en 4ème position dans la liste du champ. On prendre donc `locationCity = location.area[3]` en prenant garde de **traiter le cas où aucune ville n’est renseignée**.
- `salaire_min` et `salaire_max` → `salary` : calculer la moyenne des 2 champs.